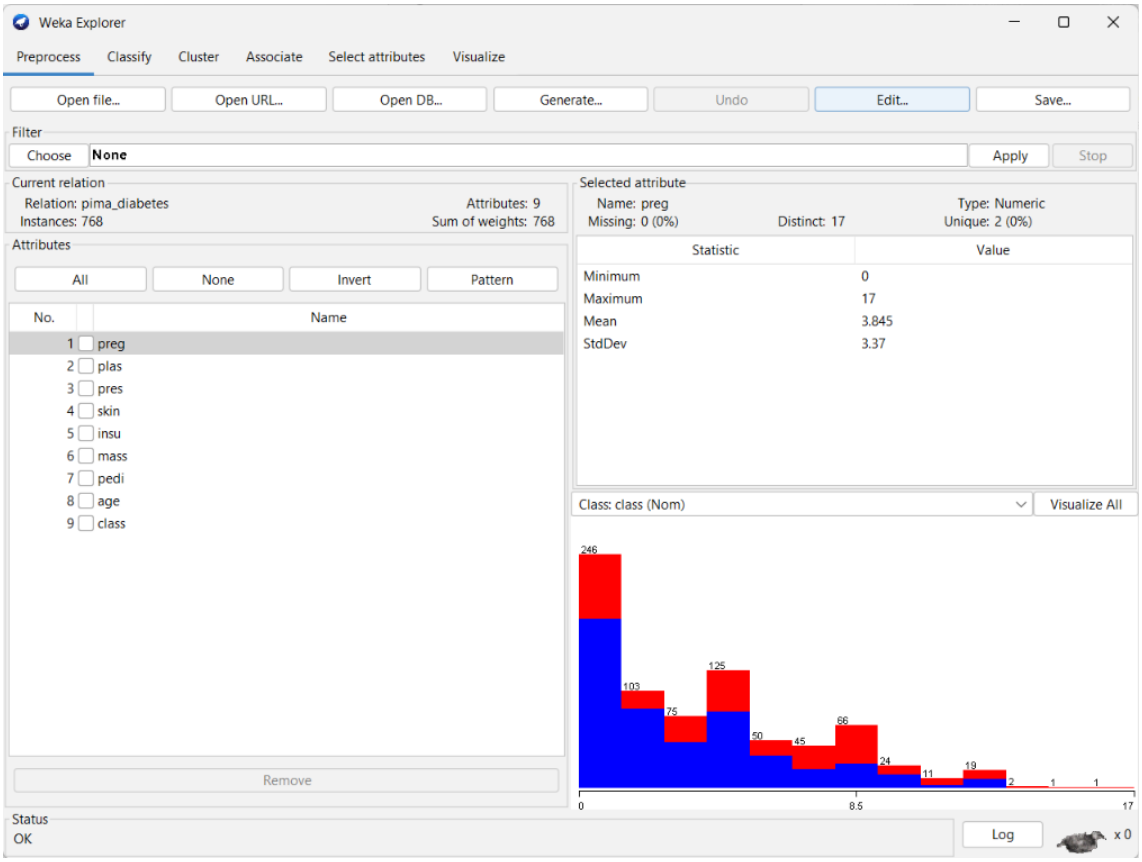
WEKA – PIMA INDIANS DIABETES DATA

Estudiante: Echegoyen Rojas Anahi Shannel

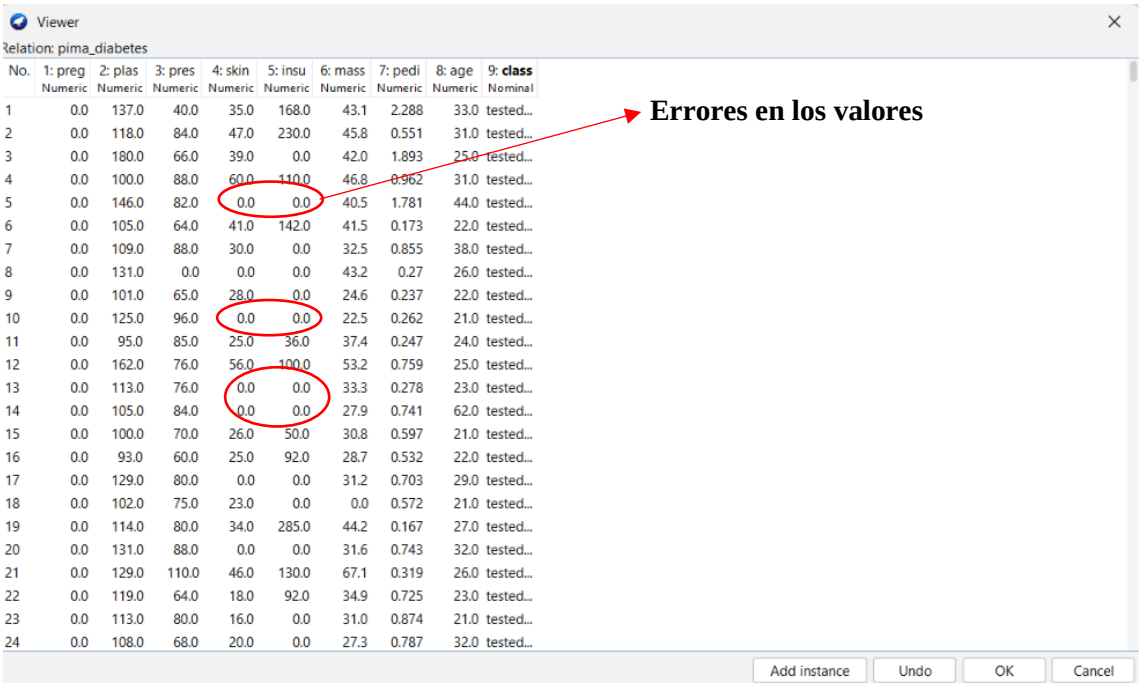
1. Descripción de variables:

Variable	*Significado*	*Unidad*	*Rango Válido*
preg	N° de veces embarazada	Conteo	≥0
plas	Concentración de glucosa en plasma	Mg/dL	>0
pres	Presión arterial	mmHg	>0
skin	Grosor del pliegue cutáneo	mm	>0
insu	Insulina sérica	Mu U/ml	>0
mass	IMC	Kg/m^2	>0
pedi	Función pedigrí de diabetes	continuo	Cualquier valor +
age	Edad	años	≥21
class	Variable objetivo	Tested_negative Tested_positive	-

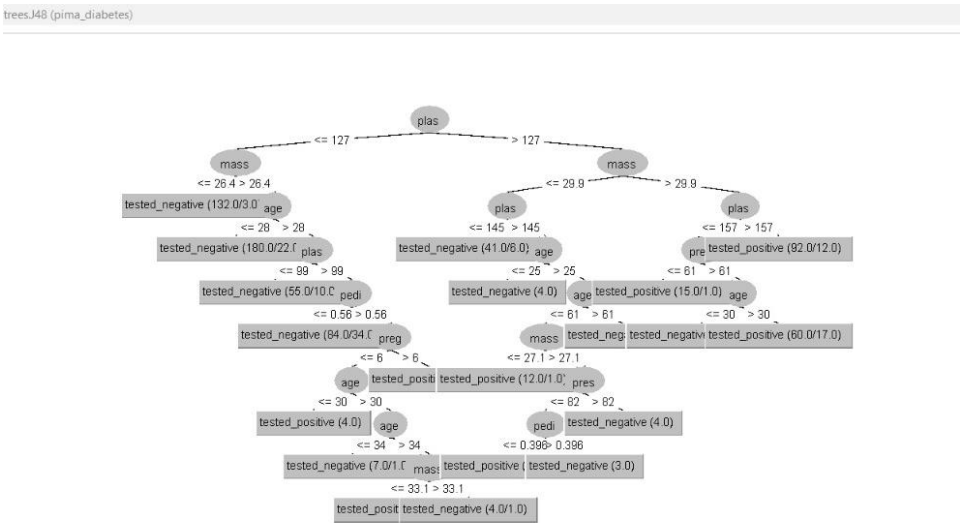


2. Diagnóstico de la data:

Variable	*Cant. De ceros*	*% del total*	*¿Es un error?*
preg	111	14.5%	No
plas	5	0.7%	Sí
pres	35	4.6%	Sí
skin	227	29.6%	Sí
insu	374	48.7%	Sí
mass	11	1.4%	Sí
pedi	0	0%	Sin problema
age	0	0%	Sin problema



3. Árbol J48 de la data sin limpiar:

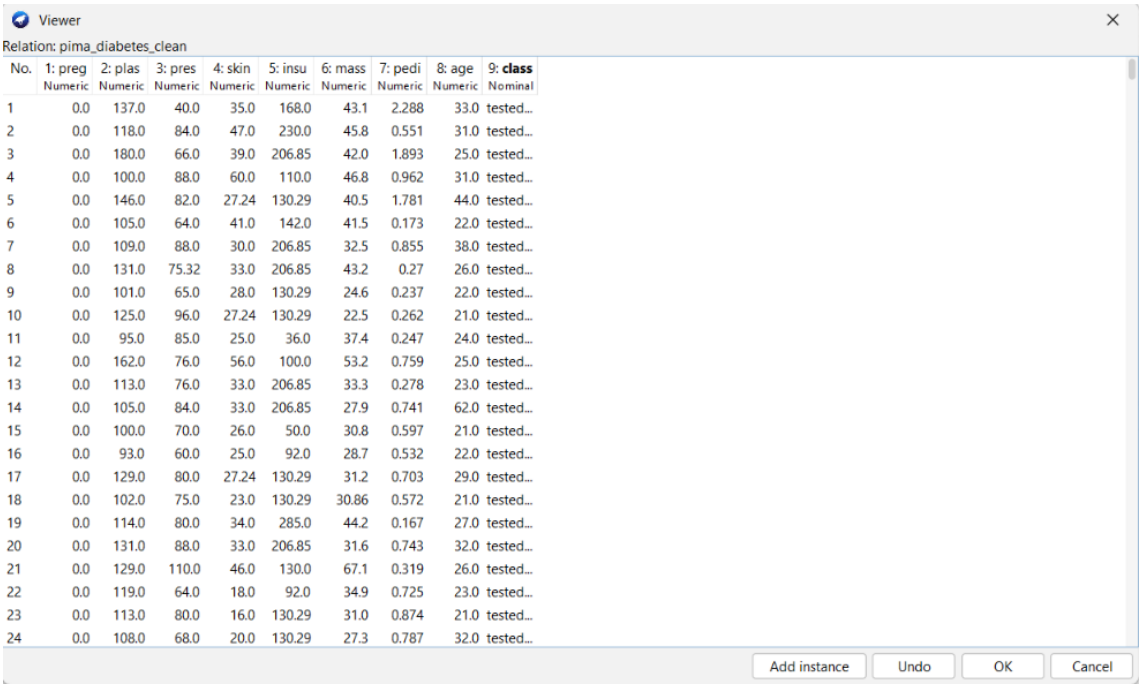


4. **Limpieza del DATA:**

Después de sacar la media de todos los datos y separarlos en dos grupos: los que salieron positivos y negativos, se obtuvieron estos valores, los cuales se reemplazo en la tabla anteriormente mostrada, en aquellos valores que resultaban 0.

Variable	*Media en tested_negative*	*Media en tested_positive*
plas	110.64	142.32
pres	70.88	75.32
skin	27.24	33.00
insu	130.29	206.85
mass	30.86	35.41

Al final, la tabla quedo asi:



No.	1: preg Numeric	2: plas Numeric	3: pres Numeric	4: skin Numeric	5: insu Numeric	6: mass Numeric	7: pedi Numeric	8: age Numeric	9: class Nominal
1	0.0	137.0	40.0	35.0	168.0	43.1	2.288	33.0	tested...
2	0.0	118.0	84.0	47.0	230.0	45.8	0.551	31.0	tested...
3	0.0	180.0	66.0	39.0	206.85	42.0	1.893	25.0	tested...
4	0.0	100.0	88.0	60.0	110.0	46.8	0.962	31.0	tested...
5	0.0	146.0	82.0	27.24	130.29	40.5	1.781	44.0	tested...
6	0.0	105.0	64.0	41.0	142.0	41.5	0.173	22.0	tested...
7	0.0	109.0	88.0	30.0	206.85	32.5	0.855	38.0	tested...
8	0.0	131.0	75.32	33.0	206.85	43.2	0.27	26.0	tested...
9	0.0	101.0	65.0	28.0	130.29	24.6	0.237	22.0	tested...
10	0.0	125.0	96.0	27.24	130.29	22.5	0.262	21.0	tested...
11	0.0	95.0	85.0	25.0	36.0	37.4	0.247	24.0	tested...
12	0.0	162.0	76.0	56.0	100.0	53.2	0.759	25.0	tested...
13	0.0	113.0	76.0	33.0	206.85	33.3	0.278	23.0	tested...
14	0.0	105.0	84.0	33.0	206.85	27.9	0.741	62.0	tested...
15	0.0	100.0	70.0	26.0	50.0	30.8	0.597	21.0	tested...
16	0.0	93.0	60.0	25.0	92.0	28.7	0.532	22.0	tested...
17	0.0	129.0	80.0	27.24	130.29	31.2	0.703	29.0	tested...
18	0.0	102.0	75.0	23.0	130.29	30.86	0.572	21.0	tested...
19	0.0	114.0	80.0	34.0	285.0	44.2	0.167	27.0	tested...
20	0.0	131.0	88.0	33.0	206.85	31.6	0.743	32.0	tested...
21	0.0	129.0	110.0	46.0	130.0	67.1	0.319	26.0	tested...
22	0.0	119.0	64.0	18.0	92.0	34.9	0.725	23.0	tested...
23	0.0	113.0	80.0	16.0	130.29	31.0	0.874	21.0	tested...
24	0.0	108.0	68.0	20.0	130.29	27.3	0.787	32.0	tested...

Sin ningún valor 0.

5. Nuevo Árbol J48 con la Data ya limpia:

ma_diabetes_clean)

